Prompt 工程系统学习报告

理论方法 评测体系与 KARMA 知识抽取实践

阶段学习报告

汇报人 _____

日期 2026 年 9 月

摘要

本报告围绕 Prompt 工程的概念边界、设计方法、评测体系、安全风险与知识抽取应用展开系统梳理。学习材料从入门教程扩展到官方技术文档、综述论文、代表性研究、评测框架和安全指南，并结合 KARMA 项目现有实体发现与关系抽取提示词进行案例分析。报告的核心判断是：高质量 Prompt 不是一段修辞精巧的指令，而是一份可执行、可验证、可迭代的任务规格；Prompt 工程的成熟形态也不只是措辞优化，而是由任务定义、上下文组织、结构化接口、评测数据和运行治理共同构成的系统工程。

在方法层面，本报告区分零样本与少样本提示、思维链与任务分解、自洽采样、程序辅助推理、检索增强、工具调用和结构化输出等技术，并强调这些方法并非普遍有效，必须依据任务类型、模型特性、成本限制和失败模式进行选择。在应用层面，报告将上述原则落到知识图谱构建场景，指出 KARMA 当前 Prompt 的主要改进空间集中在规则冲突、证据边界、复合实体原子化、模态与否定表达、两阶段修订锚定以及模型自评偏差等方面。最后，报告提出一套可直接执行的对照实验与组会 PPT 叙事框架，使后续学习从“阅读更多材料”转向“用证据验证设计假设”。

关键词 Prompt 工程 上下文工程 大语言模型评测 结构化输出 知识抽取 KARMA

目录

第一章 学习目标与研究范围

第二章 Prompt 工程的概念与发展

第三章 Prompt 设计的核心方法

第四章 上下文工程与知识接入

第五章 评测驱动的 Prompt 开发

第六章 安全 鲁棒性与运行治理

第七章 信息抽取与知识图谱场景

第八章 KARMA 项目 Prompt 案例分析

第九章 核心结论与认知升级

第十章 后续学习与组会汇报设计

附录 术语速查与学习资源

参考文献

第一章 学习目标与研究范围

学习背景

此前接触的 Prompt 工程内容多以技巧清单为主，例如指定角色、补充上下文、要求分步思考或提供示例。这些做法有一定实用价值，但如果缺少任务定义、评价标准与失败分析，就容易出现“同一批技巧换一种说法”的重复感。本阶段学习因此不再以收集模板为目标，而是试图回答更基础的问题：模型为何会受提示影响，提示怎样与数据、工具和输出接口共同工作，效果如何被可靠测量，以及一个 Prompt 如何从个人经验转化为团队可复用资产。

学习范围与资料方法

本报告所依据的学习材料分为五类：官方文档用于把握当前产品能力与推荐实践；综述用于建立统一术语和技术地图；代表性论文用于理解方法的原始问题、实验设置与适用边界；评测与安全资料用于补足教程中常被忽略的可靠性问题；KARMA 本地 Prompt 与项目文档用于验证理论能否解释真实工程现象。Prompt Report 对 33 个相关术语和 58 类文本提示技术进行了系统梳理，说明 Prompt 工程已经形成较大的方法谱系，但方法数量本身并不等于工程成熟度。[1]

表一 学习资料的功能分工

资料类型	主要用途	本报告的使用方式
官方文档	确认当前能力 边界与接口	核对推理模型提示 结构化输出和评测流程
综述与教程	建立知识地图和共同术语	整理方法家族 选择学习主线
代表性论文	理解方法提出的真实问题	关注实验条件 收益来源与失效边界
评测与安全资料	识别平均分之外的风险	设计失败分类 注入防护与回归测试
项目材料	把理论转化为可验证问题	分析 KARMA 实体和关系 Prompt 并提出实验

报告重点

本报告不追求平均介绍所有技巧，而把重点放在三个层次。第一层是 Prompt 作为任务规格的基本结构，决定模型是否理解目标、约束与输出契约；第二层是评测驱动的迭代流程，决定改动是否真正提升质量；第三层是知识抽取场景中的证据性、原子性和一致性，决定结果能否进入后续知识图谱。

对组会而言，最值得强调的不是“我学会了多少种 Prompt 写法”，而是“我建立了什么判断框架，并准备如何用实验验证”。

第二章 Prompt 工程的概念与发展

Prompt 工程的定义

Prompt 工程可以定义为围绕大语言模型输入进行设计、测试、评估和维护的过程，其目标是在给定模型、数据与成本约束下稳定实现任务行为。这里的 Prompt 不仅是用户提出的问题，还包括系统指令、上下文材料、示例、工具说明、输出模式和对话历史。因此，一个生产级 Prompt 更接近“自然语言编写的接口契约”，而不是一句灵感式命令。

模型为什么会受 Prompt 影响

大语言模型根据当前上下文预测后续内容，Prompt 改变了模型所处的条件分布。指令告诉模型要完成什么任务，示例提供任务在当前上下文中的局部模式，检索材料提供可引用事实，输出模式限制结果的外部形态。由于同一语义可以有多种表达，而模型训练目标并不等同于用户的业务指标，提示措辞、示例顺序、上下文位置甚至无关文本都可能改变输出。研究发现少样本示例的排列顺序会显著影响结果，长上下文中的关键信息放在中部时也可能更难被利用。[6][11]

从提示词技巧到上下文与评测工程

Prompt 工程的发展重心正在从“如何写一句更聪明的话”转向“如何组织模型一次决策所需的全部信息”。当系统包含检索、记忆、工具、多个智能体和结构化接口时，真正需要设计的是上下文的选择、排序、压缩、可信度和生命周期，这通常被概括为上下文工程。同时，模型或版本变化会导致既有 Prompt 性能漂移，单靠主观阅读无法判断好坏，因此评测工程成为另一条主线。成熟系统的基本循环是先定义成功标准，再建立测试集，随后修改 Prompt 并进行回归验证，而不是凭少数成功样例确定方案。

技术边界

Prompt 并不能弥补所有问题。知识缺失通常需要检索或外部数据库，确定性计算适合交给代码和工具，稳定格式需要结构化输出约束，复杂业务规则可能需要拆分工作流，而高风险结论还需要人工复核。若一个问题本质上来自脏数据、标签定义不清、检索召回不足或模型能力不匹配，继续增加提示文本往往只会提高复杂度。识别何时不该继续调 Prompt，本身就是 Prompt 工程的重要能力。

第三章 Prompt 设计的核心方法

把任务写成可执行规格

一个稳健 Prompt 首先需要把含糊目标转换为可执行规格。规格至少应说明任务目标、输入边界、允许与禁止的行为、判断标准、输出字段以及异常情况的处理方式。例如“抽取重要实体”并不可测，因为“重要”和“实体”的边界没有定义；改写为“仅抽取原文中可定位的生物医学实体，保持原文跨度，排除纯数量与无独立语义修饰词，并按给定类型返回”后，任务才具备一致标注和评测的可能。

指令 上下文 示例与输出契约

Prompt 可以拆为四个相互依赖的组成部分。指令规定行动和优先级；上下文提供完成任务所需的事实；示例把抽象规则转化为局部行为参照；输出契约规定字段、类型和失败返回。四者的顺序不是唯一的，但职责应清晰，外部材料与指令应有明显边界。对长任务而言，先给出简短目标，再给规则与数据，最后重复最关键的输出要求，通常比在单段文字中混合所有信息更便于维护。

零样本与少样本提示

零样本提示适合规则清晰、模型已有较强先验的任务，维护成本低，但容易暴露标签边界不一致的问题。少样本提示通过示例校准输出风格和决策边界，尤其适合分类、抽取和规范化任务；其关键不在示例数量，而在覆盖典型样例、边界样例、反例和易混淆样例。示例还应避免泄露测试答案或携带与任务无关的表面规律。由于示例顺序会引起波动，最终方案需要在多种顺序和不同样本上验证，而不能只选择一次效果最好的排列。[6]

推理 分解与自洽

思维链提示通过展示或诱导中间推理步骤，在算术、常识和符号推理等任务上表现出能力涌现。[2] 自洽方法则对多个推理路径进行采样并汇总答案，以减少单一路径的偶然错误。[3] Least-to-Most 通过先解决子问题再组合答案，缓解复杂任务的一步跳跃。[4] 这些技术的共同本质是改变推理搜索过程，但并非越长越好。对于当前推理模型，官方建议通常是保持指令直接、给足约束和成功标准，不必机械要求“逐步思考”，因为模型可能已在内部进行推理，额外要求反而带来冗余。[18]

程序辅助推理与工具使用

当任务包含精确计算、数据库查询或外部操作时，将可验证步骤交给工具通常比要求模型纯文本推理更可靠。PAL 让模型生成程序并由执行器完成计算；ReAct 把推理与行动交替组织，使模型可以查

询环境、观察结果并继续决策。[5][7] 工程上的关键是明确工具何时可用、参数如何构造、调用失败如何处理以及最终答案如何引用工具结果。工具调用不是让模型“更聪明”，而是把模型擅长的语义判断与外部系统擅长的确定性操作分开。

结构化输出

结构化输出把自然语言响应限制为预定义模式，可显著减少 JSON 语法错误、字段缺失和类型漂移，并便于下游程序消费。当前官方文档建议在需要稳定机器接口时使用 JSON Schema 等约束，而不是只在 Prompt 中写“请返回 JSON”。[20] 但结构正确不代表语义正确：实体可以被放进合法字段却仍然抽错，关系可以符合枚举却没有文本证据。因此结构化输出解决的是接口层可靠性，事实性和任务正确性仍需独立评测。

表二 主要方法的用途与边界

方法	主要解决的问题	常见风险	适合的验证方式
少样本提示	标签边界和输出风格不清	顺序敏感 示例偏置	换序测试 边界集测试
思维链与任务分解	多步推理和组合困难	冗长 错误链条被放大	按难度分层测试
自洽采样	单次推理偶然性	成本升高 多数答案也可能错	准确率 成本 延迟联合评估
工具调用	计算 查询和外部动作	参数错误 工具结果误读	执行成功率 结果一致性
结构化输出	字段和格式不稳定	合法格式掩盖语义错误	模式通过率加任务指标

第四章 上下文工程与知识接入

上下文工程的对象

上下文工程关注模型在一次决策中究竟看见什么，以及这些信息以什么顺序、可信度和粒度出现。系统指令、历史对话、检索片段、用户输入、工具返回、记忆和中间结果都会竞争有限的注意力。工程目标不是把所有材料都塞进窗口，而是让当前决策所需的高价值信息更容易被发现，同时减少过期、重复、互相冲突和不可信内容。

长上下文并不等于可靠记忆

更长的上下文窗口扩大了可输入的信息量，但没有自动解决信息利用问题。“Lost in the Middle”研究表明，模型对长上下文不同位置的信息利用并不均匀，关键证据位于开头或结尾时往往优于位于中部。[11] 因此长文任务仍需检索、分块、排序和摘要。对知识抽取而言，如果定义、示例、源文本和历史结果同时存在，应优先保证当前源文本与核心规则靠近决策位置，并明确历史结果只能作为待审对象，而不是事实证据。

检索增强生成

检索增强生成通过在推理前检索外部知识，为模型提供可追溯依据。它适合知识更新快、材料规模大或答案必须依赖私有文档的任务。检索质量需要分别考察召回、排序、片段完整性和答案引用，不能把最终回答错误全部归因于 Prompt。如果正确证据从未进入上下文，生成模型再强也无法稳定恢复；反之，检索到大量相似但冲突的片段，也可能使模型产生貌似有依据的错误综合。

上下文的生命周期

多轮或多智能体系统还需要管理上下文的生命周期。短期状态应记录当前任务和已完成步骤，长期记忆只保留经验证且有复用价值的信息，工具结果要附带来源和时间，模型生成的中间结果则应标记为推断而非证据。KARMA 的多智能体流程尤其需要区分“原始文献内容”“上游智能体的候选输出”和“经过验证的知识”，否则错误会在代理之间被继承，并因重复出现而获得虚假的可信度。

第五章 评测驱动的 Prompt 开发

评测为什么是核心

Prompt 优化最容易陷入的误区是凭少量演示样例和阅读感受判断效果。语言输出具有随机性，测试样例也可能恰好迎合某种措辞；没有固定数据集和指标，任何改动都无法区分真实提升与偶然波动。官方评测指南建议从目标、数据集、指标和持续评测流程出发，把评测贯穿开发和上线阶段。[19] 因而 Prompt 工程的顺序应当是先定义什么算成功，再写初版 Prompt，随后根据失败类型进行有针对性的修改。

评测集与数据切分

有效评测集需要同时覆盖常规样例、边界样例、对抗样例和真实失败样例，并将开发集与最终测试集分离。知识抽取任务还应按实体类型、关系类型、句子复杂度、否定和模态、并列结构、跨句依赖等维度分层统计。这样才能看出总体 F1 提升是否以牺牲某类关键事实为代价。线上出现的新错误应进入回归集，使系统不再重复犯同一种错误。

指标与错误分类

单一平均分不足以描述 Prompt 质量。抽取任务应至少报告精确率、召回率、F1、跨度完全匹配率、结构合法率和关键类型的分组结果；生产系统还应记录延迟、Token 成本、拒答率和稳定性。更重要的是建立错误分类，例如漏抽、边界过宽、过度拆分、关系方向错误、否定误判、模态事实化、无证据补全和格式错误。错误分类把“结果不好”转换为可修正原因，也是连接 Prompt 修改与模型行为的桥梁。

模型评审的价值与限制

使用大模型作为评审可以降低开放式任务的评测成本，适合比较解释质量、风格或语义一致性，但它不是绝对裁判。研究显示 LLM 评审可能存在位置偏差、冗长度偏好、自我偏好和对提示措辞敏感等问题。[13][14] 更稳妥的做法是优先使用可确定计算的指标；必须使用模型评审时，提供清晰评分量表、交换候选顺序、使用多次评审或多评审者，并用人工标注子集校准。特别要避免让生成答案的同一模型直接给自己的答案打高分而没有外部核验。

迭代与版本管理

Prompt 应像代码一样具有版本、变更说明和回归记录。每次修改最好对应一个明确假设，例如“加入否定反例可减少把未观察到的事件抽为肯定事实”，然后在固定评测集上比较基线与新版本。除平均

指标外，还要保存逐样例差异，检查新版本修复了哪些错误、又引入了哪些退化。只有在质量、成本和延迟达到预设门槛后，改动才应进入主流程。

第六章 安全 鲁棒性与运行治理

提示注入

提示注入发生在不可信输入试图改变系统原有指令时。攻击内容可能直接来自用户，也可能隐藏在网页、文档、邮件或检索片段中。OWASP 将其列为生成式 AI 应用的重要风险，并强调仅靠一句“忽略恶意指令”不能形成可靠防护。[17] 对知识抽取系统而言，论文原文、网页内容和数据库字段都必须被视为数据；Prompt 应明确数据边界，工具权限应遵循最小化原则，高影响动作应要求独立校验或人工确认。

鲁棒性与分布变化

Prompt 可能在原始测试集上表现良好，却在换一种写法、语言、文体或模型版本后退化。近期研究进一步指出，提示优化结果具有明显的模型与任务依赖性，细微措辞变化也可能改变排名。[12] 因此鲁棒性测试应包括同义改写、示例换序、格式扰动、无关文本插入、长短文变化和跨模型复测。对高风险场景，报告最好给出分布外样例的失败上限，而不是只展示最佳结果。

运行治理

生产环境中的 Prompt 治理包括访问控制、日志、版本追踪、隐私处理、失败降级和人工复核。日志应记录模型版本、Prompt 版本、输入来源、工具调用和结构校验结果，同时避免保存不必要的敏感数据。系统还需要明确何时拒答、何时重试、何时切换备用模型，以及何时把结果交给人工。治理的价值在于把偶发的模型输出纳入可追责流程，而不是假设一次成功调用就等于可靠系统。

第七章 信息抽取与知识图谱场景

任务特征

信息抽取与一般问答的不同在于，输出必须同时满足证据约束、边界约束、类型约束和结构约束。一个三元组即使常识上正确，只要原文没有表达，也不应被视为正确抽取；一个实体名称大体相同，但跨度包含多余修饰语，也会影响后续对齐和去重。知识图谱构建还会放大局部错误：错误实体可能生成多条错误关系，并进一步污染模式对齐和冲突消解。

开放抽取与模式约束

传统开放信息抽取强调从文本中发现关系而不预设固定模式，适合探索未知结构，但输出异构、难以直接对齐。[15] 固定模式抽取便于评价和入库，却可能遗漏新实体类型或新关系。EDC 提出 Extract Define Canonicalize 流程，先开放抽取，再生成定义并进行规范化，试图兼顾发现能力与模式一致性。[9] 这说明 Prompt 设计不能只选择“开放”或“封闭”，更可行的是把发现、定义、规范化和验证拆成不同阶段。

用指南而不只是标签

GoLLIE 的核心思想是把人类编写的标注指南作为模型输入，使模型不仅看到标签名称，还理解标签的语义边界和判定规则，并在未见模式上提升零样本抽取能力。[8] 这一思路对 KARMA 很重要：诸如 Gene、Disease 或 Regulates 等标签名称不足以处理复合短语、否定、推测和事件名词化，Prompt 应包含面向判定的定义、正反例和冲突优先级。指南的目标不是把所有规则塞进一段话，而是让相似样例能够得到一致处理。

KARMA 方法的启示

KARMA 论文描述了由九个协作智能体组成的知识图谱富化框架，覆盖实体发现、关系抽取、模式对齐和冲突消解。论文报告在 1200 篇 PubMed 文章上发现最多 38230 个新实体，LLM 验证正确率为 83.1%，并使冲突边减少 18.6%。[16] 这些数字应理解为论文特定实验设置下的报告结果，而不是当前本地版本已经复现的结论。更重要的启示是：多智能体把复杂任务分解为可管理阶段，但系统质量取决于阶段间证据传递、错误隔离和独立验证，智能体数量本身并不保证可靠性。

表三 三类知识抽取思路的比较

方法	核心设计	优势	需要注意的边界
GoLLIE	用自然语言标注指南约束抽取	增强未见模式的零样本泛化	指南质量和上下文长度会影响效果
EDC	抽取 定义 规范化分阶段完成	兼顾开放发现与模式对齐	阶段误差会传递 规范化需独立验证
KARMA	多智能体协作完成图谱富化	任务分工清晰 支持冲突处理	需审查证据链 自评偏差和代理间锚定

第八章 KARMA 项目 Prompt 案例分析

现有 Prompt 的总体特征

本地项目的实体发现与关系抽取 Prompt 已经具备较好的工程意识：使用 system 与 user 角色区分全局规则和具体输入，对输出字段进行限制，并在第二阶段结合初始结果与差异信息进行修订。Prompt 还关注实体原文跨度、关系依据、置信度、清晰度和相关性。这说明项目已超越简单问答式提示，开始形成任务规格与迭代流程；下一步的关键不是继续增加规则数量，而是消除规则冲突并建立独立评测。

规则冲突与判定优先级

当前实体 Prompt 中“保持最小原子实体”与“保留完整短语”可能在复合生物医学表达上冲突，“优先精确”与“尽量完整”也可能引导模型在边界样例上采取不同策略。如果 Prompt 没有规定冲突时的优先级，模型只能依据局部措辞自行折中。建议把规则改写为分层决策：先判断候选是否具有独立语义，再确定原文跨度，最后判断是否需要拆分；同时给出应拆分、不应拆分和允许嵌套的对照例。

两阶段修订的锚定风险

第二阶段同时看到源文本、首轮结果和差异信息，能够修复遗漏与格式错误，但也容易被首轮答案锚定。若首轮把一个复合短语整体当作实体，修订模型可能只在既有候选附近微调，而不会重新搜索文本。建议把修订分为“独立重抽取”和“差异裁决”两个子阶段：先仅依据原文生成候选，再与旧结果比较；差异裁决时要求为保留、删除和新增项分别给出文本证据。这样可以降低错误答案因重复出现而被误认为可靠事实的风险。

自评指标的局限

项目当前让同一模型在生成三元组的同时给出 confidence、clarity 和 relevance 等分数，这些字段有助于排序，但不应直接当作客观质量。模型可能对流畅但错误的关系给出高置信度，也可能因知道自己的生成理由而产生自我偏好。更可靠的做法是把分数解释为“模型内部主观信号”，并与外部证据共同使用，例如跨度匹配、关系词触发、独立评审模型、人工标注子集和跨次一致性。

需要单独覆盖的语言现象

生物医学文本中最容易造成事实失真的现象包括否定、推测、条件、数量限定、并列结构、比较关系、指代和跨句关系。比如“可能抑制”不能无条件规范化为“抑制”，“A 和 B 分别作用于 C 和 D”不能

简单展开为四条关系，“未观察到 X 导致 Y”更不能抽为肯定因果。建议为这些现象建立专门的小型挑战集，并在 Prompt 中用最少但高信息量的正反例明确处理原则。

建议的 Prompt 重构框架

面向 KARMA 的 Prompt 可重构为六个连续模块：任务定义说明抽取对象；术语定义限定实体和关系边界；决策流程规定先证据后归类；冲突优先级解决原子性与完整性矛盾；输出模式保证接口稳定；自检清单检查否定、模态、跨度和无证据补全。每个模块都应能对应至少一类评测用例。若某条规则无法对应可观察错误或测试样例，它很可能只是增加长度而没有增加控制力。

建议的对照实验

实验应从可回答的假设出发，而不是一次性替换全部 Prompt。优先选择约 100 至 200 条人工复核样例，保持模型、温度和解析流程一致，分别比较基线 Prompt 与单因素改动。每组实验重复多次并报告平均值与波动，同时记录逐样例变化。这样既能找到有效规则，也能识别看似提高总分、实则伤害关键边界类型的改动。

表四 KARMA 优先实验矩阵

实验问题	对照改动	主要指标	预期判断
规则优先级是否减少边界冲突	原 Prompt 对比分层决策 Prompt	实体跨度 F1 过度拆分率	判断原子性与完整性是否更一致
独立重抽取是否降低锚定	直接修订 对比先独立抽取再裁决	新增正确项 删除错误项召回率	判断二阶段流程是否真正发现首轮遗漏
模态反例是否抑制事实化	无反例 对比加入少量正反例	模态误判率 否定误判率	判断示例是否优于继续增加抽象规则
结构约束是否只改善格式	提示返回 JSON 对比模式约束	模式通过率 语义 F1	区分接口收益与任务收益
自评分能否预测正确性	模型自评分与人工标签对齐	相关系数 校准误差	决定自评分适合筛选还是仅作辅助

第九章 核心结论与认知升级

从技巧集合到系统工程

本阶段最重要的认知升级是：Prompt 工程的核心对象不是一句话，而是模型行为发生的完整条件。指令负责目标，数据负责证据，示例负责校准，模式负责接口，工具负责确定性能力，评测负责判断改动是否有效，治理负责控制上线风险。这些部分缺一不可。只优化措辞而忽略检索、评测或数据定义，通常只能获得局部且不稳定的改进。

从追求完美 Prompt 到建立证据循环

不存在脱离模型、任务和数据分布的通用最佳 Prompt。更合理的目标是建立一条快速而严谨的证据循环：收集失败样例，形成错误分类，提出单一改动假设，运行固定评测，检查收益与回退，再把新失败加入回归集。Prompt 在这一循环中只是可调组件之一。自动 Prompt 优化研究进一步说明，候选生成、搜索和评估可以部分自动化，但自动化仍依赖可靠目标函数，否则系统只会更高效地迎合错误指标。[10]

从输出流畅到结果可信

语言模型最容易制造的错觉是把表达质量误认为事实质量。结构完整、解释顺畅或置信度很高，都不能代替证据核对。对 KARMA 而言，每个实体和关系都应尽可能回指原文跨度或句段，规范化结果要与原始证据分开保存，推测性结论要保留模态，模型自评分要与外部标注校准。只有把可追溯性纳入输出设计，知识图谱才不会把语言生成的不确定性固化为数据库事实。

常见误区

常见误区包括把角色设定当作主要质量来源、认为 Prompt 越长越专业、把思维链当作所有任务的默认配置、把 JSON 合法等同于内容正确、用少数成功案例替代评测，以及把 LLM 评审当作没有偏差的金标准。更好的判断方式是询问：这段设计解决了哪一种可观察错误，是否有数据证明，是否带来成本或延迟代价，模型或数据变化后是否仍然成立。

当前学习重点排序

若时间只有一周，学习优先级应当是任务规格与评测体系，其次是少样本设计、结构化输出和上下文工程，再次是推理、工具和自动优化方法。原因是前两项决定后续实验是否可解释。对于本项目，最值得深入的论文不是数量最多的 Prompt 技巧综述，而是与信息抽取、标注指南、开放模式发现、长

上下文和评审偏差直接相关的工作。论文需要阅读，但应以问题为单位精读方法、实验和局限，不必从头到尾平均用力。

第十章 后续学习与组会汇报设计

一周学习与实验安排

后续一周建议采用“概念建立—方法精读—项目诊断—小规模实验—汇报整合”的节奏。前两天完成官方文档和核心论文的结构化阅读，第三天建立 KARMA 错误分类与人工复核样例，第四至第五天运行一到两个单因素对照实验，第六天整理图表和案例，第七天压缩为组会叙事。每天都应产生可复用产物，例如一页论文卡片、一组失败样例或一张实验表，而不是只记录阅读时长。

组会 PPT 的中心叙事

PPT 不宜按网站或论文逐个介绍，而应围绕一个中心判断展开：Prompt 工程已经从提示词技巧发展为面向模型行为的系统工程，评测是连接设计与可靠性的核心，而 KARMA 提供了一个可以验证这些原则的真实场景。建议先用一个失败案例制造问题，再给出概念框架与代表方法，随后展示 KARMA 诊断和实验设计，最后总结可执行的下一步。这样老师看到的不是资料汇编，而是从学习到研究问题的转化。

表五 建议的组会 PPT 结构

页次	页面主题	要回答的问题	建议素材
1	问题与目标	为什么普通 Prompt 教程不够	一个 KARMA 失败案例
2	核心定义	Prompt 工程到底是什么	任务规格到工程闭环示意
3	方法地图	常用方法分别解决什么问题	方法家族比较表
4	上下文与工具	为什么不只是改措辞	检索 工具 结构输出流程
5	评测框架	如何证明 Prompt 更好	数据集 指标 错误分类
6	安全与鲁棒性	系统为何会在真实环境失效	提示注入和分布变化案例
7	知识抽取研究	代表工作带来什么启示	GoLLIE EDC KARMA 对比
8	本地 Prompt 诊断	KARMA 当前最值得改什么	规则冲突 锚定 自评偏差
9	实验方案	下一步如何验证	单因素对照实验矩阵
10	结论	本阶段真正学到了什么	三条核心结论与行动计划

预期研究产出

如果按上述方案推进，本阶段可形成四类产出：一套可复用的 Prompt 任务规格模板，一份面向知识抽取的错误分类表，一个经过人工核验的小型回归评测集，以及至少一组可复现的 Prompt 对照实验。它们比单次汇报更有长期价值，因为后续更换模型、增加实体类型或调整多智能体流程时，仍可用同一套标准验证变化。

附录 术语速查与学习资源

核心术语

下列术语用于统一后续学习和汇报表达。Prompt 指提供给模型的全部输入组织，而不只是一句用户问题；上下文工程指选择、组织和管理模型决策时可见的信息；结构化输出指用模式约束响应外形；评测集是用于稳定比较版本的数据样本；回归测试用于确认修复新问题时没有重新引入旧问题；提示注入是不可信数据试图改变系统指令的攻击方式。

术语	简要解释	在 KARMA 中的对应对象
任务规格	目标 约束 成功标准与异常处理的统一描述	实体和关系的定义及判定优先级
上下文工程	管理模型一次决策可见的信息	原文 初始结果 差异信息与指南的组织
少样本提示	用少量示例校准标签边界和输出行为	复合实体 否定 模态和并列关系示例
结构化输出	用模式保证字段和类型稳定	实体列表 三元组及其证据字段
LLM 评审	用模型对候选输出进行评分或比较	正确性 清晰度和相关性评估
回归集	长期保留的已知失败样例集合	每次 Prompt 改动必须重新通过的样例

推荐学习资源

学习资源应按问题使用，而不是从头浏览。需要核对当前接口和推荐实践时优先看模型厂商官方文档；需要建立方法地图时看 Prompt Report 与 Prompting Guide；需要深入推理方法时阅读 CoT、Self Consistency、Least to Most、PAL 与 ReAct 原论文；需要处理知识抽取时重点阅读 GoLLIE、EDC 和 KARMA；需要设计实验时参考官方 Evals 指南与 Promptfoo；需要审查安全时查看 OWASP 提示注入资料。每次阅读建议记录“解决的问题、核心机制、实验条件、局限、与 KARMA 的关系”五项，而不是摘抄全文。

资源	适合解决的问题	链接
OpenAI Prompt Engineering	当前提示设计与模型使用建议	https://developers.openai.com/api/docs/guides/prompt-engineering
OpenAI Evals	建立数据集 指标与持续评测	https://developers.openai.com/api/docs/guides/evals

资源	适合解决的问题	链接
Prompting Guide	快速查阅方法分类和示例	https://www.promptingguide.ai/
Learn Prompting	按课程顺序补充基础与安全	https://learnprompting.org/docs/introduction
Promptfoo	把 Prompt 对照实验转成自动化测试	https://www.promptfoo.dev/docs/guides/
OWASP LLM Prompt Injection	建立提示注入威胁模型	https://genai.owasp.org/llmrisk/llm01-prompt-injection/

参考文献

参考文献覆盖方法综述、推理技术、知识抽取、长上下文、评审偏差、安全规范与官方实践。后续精读时应以研究问题为主线核对原始实验，不把论文标题或摘要中的结论直接推广到当前模型与项目数据。

[1] Schulhoff S 等. The Prompt Report: A Systematic Survey of Prompting Techniques. arXiv:2406.06608, 2024.

[2] Wei J 等. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS, 2022.

[3] Wang X 等. Self-Consistency Improves Chain of Thought Reasoning in Language Models. ICLR, 2023.

[4] Zhou D 等. Least-to-Most Prompting Enables Complex Reasoning in Large Language Models. ICLR, 2023.

[5] Gao L 等. PAL: Program-aided Language Models. ICML, 2023.

[6] Lu Y 等. Fantastically Ordered Prompts and Where to Find Them. ACL, 2022.

[7] Yao S 等. ReAct: Synergizing Reasoning and Acting in Language Models. ICLR, 2023.

[8] Sainz O 等. GoLLIE: Annotation Guidelines Improve Zero-Shot Information-Extraction. ICLR, 2024.

[9] Zhang Y 等. EDC: Extracting Large-Scale Knowledge Graphs with Large Language Models. EMNLP, 2024.

[10] Zhou Y 等. Large Language Models Are Human-Level Prompt Engineers. ICLR, 2023.

[11] Liu N F 等. Lost in the Middle: How Language Models Use Long Contexts. TACL, 2024.

[12] Mizrahi M 等. State of What Art? A Call for Multi-Prompt LLM Evaluation. TACL, 2024.

[13] Shi L 等. Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge. IJCNLP-AACL, 2025.

[14] Koo R 等. Benchmarking Cognitive Biases in Large Language Models as Evaluators. EMNLP, 2024.

[15] Niklaus C 等. A Survey on Open Information Extraction. COLING, 2018.

[16] Sun 等. KARMA: Leveraging Multi-Agent LLMs for Automated Knowledge Graph Enrichment. arXiv:2502.06472, 2025.

[17] OWASP. LLM01 Prompt Injection. OWASP GenAI Security Project. https://genai.owasp.org/llmrisk/llm01-prompt-injection/

[18] OpenAI. Reasoning Best Practices. https://developers.openai.com/api/docs/guides/reasoning-best-practices

[19] OpenAI. Evaluation Best Practices. https://developers.openai.com/api/docs/guides/evals

[20] OpenAI. Structured Outputs. https://developers.openai.com/api/docs/guides/structured-outputs

[21] Anthropic. Prompt Templates and Variables. https://docs.anthropic.com/en/docs/build-with-claude/prompt-engineering/prompt-templates-and-variables

[22] Google Cloud. Prompt Design Strategies. https://cloud.google.com/vertex-ai/generative-ai/docs/learn/prompts/prompt-design-strategies